

ASESMEN CLO SEMESTER GENAP 2024/2025
PEMODELAN DAN OPTIMASI LANJUT (DAY)

Nama Anggota Kelompok:

Muhammad Abiya Makruf (203012420034)

Muhammad Rafly Arjasubrata (203012420028)

Nugroho Rahmanto (203012420029)

Pembagian Tugas:

No	Tugas	Nama
1	Mengerjakan Soal 1	Muhammad Rafly A
2	Laporan Soal 1	Muhammad Rafly A
3	Mengerjakan Soal 2 (Code)	Muhammad Abiya M
4	Mengerjakan Soal 2 (Komentar dan Analisis)	Nugroho Rahmanto
5	Laporan Soal 2	Muhammad Abiya M & Nugroho Rahmanto

Source Code Program:

No.1 <https://github.com/AbiyaMakruf/TelU-Tugas-PemodelanDanOptimasiLanjut-UTS/blob/main/no1.ipynb>

No.2 <https://github.com/AbiyaMakruf/TelU-Tugas-PemodelanDanOptimasiLanjut-UTS/blob/main/no2.ipynb>

Soal 1

Sebuah perusahaan PT. ABC bergerak dibidang manufaktur yang mempunyai relatif banyak karyawan. Pihak HRD dari perusahaan ini ingin melakukan studi terkait dengan produktivitas dari kerja karyawannya, dalam rangka meningkatkan produktivitas perusahaan secara umum. Perusahaan ingin mengetahui hubungan antara jumlah jam kerja lembur dan jumlah pelatihan teknis terhadap produktivitas kerja karyawan. Berikut ini adalah data survey terhadap 15 karyawan perusahaan tersebut, dimana di catat jumlah jam kerja lembur per-minggu, jumlah jam pelatihan teknis yang diterima, dan skor produktivitas kerja karyawan (skala 1-100):

Karyawan	Lembur (Jam)	Pelatihan (Jam)	Skor Produktivitas
1	4	6	78
2	5	8	85
3	2	5	75
4	7	7	88
5	2	4	72
6	6	5	83
7	8	9	91
8	5	7	86
9	9	8	92
10	4	5	80
11	6	6	84
12	7	10	90
13	3	3	70
14	8	8	89
15	5	6	82

1. Buatlah model regresi multivariat untuk mengetahui hubungan antara jumlah jam kerja lembur dan jumlah jam pelatihan teknis terhadap skor produktivitas kerja karyawan.

Untuk membuat model data disimpan dalam matriks dengan numpy array yang setiap barisnya direpresentasikan oleh setiap baris pada matriks seperti yang ditunjukkan pada Gambar 1.

```
1 # Buat dataset dalam bentuk array numpy
2 data = np.array([
3     [1, 4, 6, 78],
4     [2, 5, 8, 85],
5     ...
6     [14, 8, 8, 89],
7     [15, 5, 6, 82]
8 ])
```

Gambar 1. Inisialisasi data pada numpy array

Kemudian dilakukan splitting untuk fitur (X) dan label (y) untuk memisahkan variabel independent dan dependen dengan kode seperti pada Gambar 2. Reshape dilakukan pada label agar dimensi matriks tetap 2 dimensi dengan jumlah 1 kolom dan 15 baris (15 jumlah data), di mana setiap barisnya merepresentasikan label dari baris tersebut.



```
1 # Split fitur dan target
2 X = data[:, 1:3]
3 y = data[:, 3].reshape(-1, 1)
```

Gambar 2. Split fitur dengan label.


Kemudian pada matriks fitur, ditambahkan satu kolom, yaitu fitur bias. Dimana kolom bias ditambahkan untuk menyediakan konstanta (intercept) dalam model regresi linear. Nilai 1 dipilih karena nilai tersebut tidak mengubah nilai skala bias (jika dipilih 2, maka nilai parameter bias akan memiliki nilai $\frac{1}{2}$ bobot aslinya), dan jika menggunakan angka 0, maka bias tidak akan terpakai. Bias ditambahkan kepada kolom fitur menggunakan kode yang ditampilkan pada Gambar 3.



```
1 # Inisialisasi matriks bias dengan nilai 1
2 bias = np.ones((X.shape[0], 1))
3
4 # Gabungkan fitur dan bias
5 X = np.hstack((bias, X)) # Bias di kolom pertama
6 print("\nFitur dengan bias (X):")
7 print(X)
```

Gambar 3. Penambahan bias pada kolom fitur.

Matriks X yang berisi fitur dan y yang berisi label sudah dapat digunakan untuk membuat model regresi multivariate. Output dari matriks fitur digambarkan pada Gambar 4. Pada matriks tersebut, kolom pertama merepresentasikan bias, kolom kedua merepresentasikan nilai lembur, dan kolom ketiga merepresentasikan nilai pelatihan.



```
1 [[ 1.  4.  6.]
2  ...
3  [ 1.  8.  8.]
4  [ 1.  5.  6.]
```

Gambar 4. Hasil matriks fitur setelah penambahan bias.

2. Hitung bobot regresi (vektor bobot w) menggunakan regresi multivariat.

Rumus persamaan yang digunakan untuk mencari bobot w untuk bias, w_1 dan w_2 adalah :

$$\bar{w} = (X^T X)^{-1} X^T y$$


Dimana :

$\bar{w}$ = matriks bobot

X = matriks fitur

y = matriks target


kode untuk mencari bobot dari regresi multivariat berdasarkan matriks fitur dan target terdapat pada Gambar 5.



```
1 # Hitung bobot w menggunakan rumus w = (X^T * X)^(-1) * X^T * y
2
3 # 1. Transpose X (X^T)
4 XT = X.T
5
6 # 2. Perkalian matriks X^T dengan X (X^T X)
7 XTX = np.dot(XT, X)
8
9 # 3. Inverse dari (X^T X) -> (X^T X)^(-1)
10 XTX_inv = np.linalg.inv(XTX)
11
12 # 4. Perkalian matriks X^T dengan y (X^T y)
13 XTy = np.dot(XT, y)
14
15 # 5. Hitung bobot w = (X^T X)^(-1) (X^T y)
16 w = np.dot(XTX_inv, XTy)
17
18 print("Hasil Perhitungan Bobot Regresi (w)")
19 print("Vektor Bobot (w):\n", w)
```

Gambar 5. Perhitungan bobot regresi berdasarkan matriks fitur dan label yang sudah dibuat.

Hasil dari perhitungan tersebut adalah vektor bobot seperti Gambar 6. Dimana nilai intercept adalah 62.25, nilai bobot untuk lembur 2.00, dan bobot untuk pelatihan ialah 1.51. Urutan ini sesuai dengan matriks fitur seperti pada Gambar 5.



```
1 Hasil Perhitungan Bobot Regresi (w)
2 Vektor Bobot (w):
3 [[62.25      ]
4  [ 2.00634058]
5  [ 1.51268116]]
```

Gambar 6. Hasil perhitungan bobot untuk bias, w_1 , dan w_2 .

3. Berikan persamaan regresi yang diperoleh dan interpretasikan hasil bobot regresi yang didapatkan.

Berdasarkan nilai bias, w_1 , dan w_2 yang didapatkan pada Gambar 6, maka persamaan regresi yang didapatkan adalah :

$$\overline{y}_{prod} = 41.5 + 2.00 \times X_{lembur} + 1.51 \times X_{pelatihan}$$

Interpretasi dari nilai bobot ini adalah

- Intercept (41.5000): Ini adalah nilai prediksi skor produktivitas ketika jumlah jam lembur dan jumlah jam pelatihan teknis keduanya adalah 0. Secara matematis ini adalah titik potong pada sumbu Y.
- Koefisien Lembur (2.0063): Setiap penambahan 1 jam kerja lembur per minggu, dengan asumsi jumlah jam pelatihan teknis konstan, diprediksi akan meningkatkan skor produktivitas rata-rata sebesar 2.0063 poin.
- Koefisien Pelatihan Teknis (1.5127): Setiap penambahan 1 jam pelatihan teknis, dengan asumsi jumlah jam kerja lembur konstan, diprediksi akan meningkatkan skor produktivitas rata-rata sebesar 1.5127 poin.

Tabel 1 memperlihatkan 10 data pertama hasil prediksi model regresi multivariat menggunakan bobot yang sudah didapatkan.

Tabel 1. Hasil prediksi model regresi berdasarkan bobot yang sudah didapatkan.

Aktual	78	85	75	88	72	83	91	86	92	80
Prediksi	79.35	84.38	75.38	86.88	72.31	81.85	91.91	82.87	92.41	77.84

Terlihat bahwa nilai prediksi tidak terlalu jauh dari nilai aktual. Tabel 2 memperlihatkan berbagai metrik evaluasi dari model regresi yang dibangun terhadap data yang ada, dimana model yang dibangun cukup akurat untuk memprediksi skor performa berdasarkan jam lembur dan jam pelatihan teknis.

Tabel 2. Berbagai metrik evaluasi dari model yang dibangun.

Metrik Evaluasi	Nilai
Mean Squared Error (MSE)	2.2477
Root Mean Squared Error (RMSE)	1.4992
Mean Absolute Error (MAE)	1.2601
Mean Absolute Percentage Error (MAPE)	1.54%


Soal 2

Sebelum mengerjakan soal yang diberikan dilakukan *Exploratory Data Analysis* (EDA) terlebih dahulu terdapat “Electricity Load Data”. Seperti yang terlihat pada Gambar 7 terdapat 6 kolom dimana kolom terakhir yaitu “Electricity Consumption” menjadi kolom target sedangkan kolom “TIME” tidak akan digunakan dan sisa kolom menjadi kolom *features*.

	TIME	Temperature (C)	Humidity (%)	Precipitation (l/m^2)	Wind Speed (m/s)	Electricity Consumption (MWh)
0	2015-01-03 01:00:00	25.865259	0.018576	0.016174	21.850546	970.3450
1	2015-01-03 02:00:00	25.899255	0.018653	0.016418	22.166944	912.1755
2	2015-01-03 03:00:00	25.937280	0.018768	0.015480	22.454911	900.2688
3	2015-01-03 04:00:00	25.957544	0.018890	0.016273	22.110481	889.9538
4	2015-01-03 05:00:00	25.973840	0.018981	0.017281	21.186089	893.6865

Gambar 7. Isi dari Electricity Load Data

Untuk melihat hubungan antar kolom dibuatlah heatmap korelasi seperti yang terlihat pada Gambar 8 dimana terdapat hubungan yang berkorelasi positif dan berkorelasi negatif antar kolom.



Gambar 8. Heatmap Korelasi Pearson

1. Hitunglah korelasi **antara komponen cuaca** yaitu *temperature*, *humidity*, *precipitation*, dan *wind speed*, terhadap *electricity consumption*.

Untuk menghitung korelasi antara komponen cuaca dengan electricity consumption dapat menggunakan fungsi `.corr()` yang disediakan oleh library pandas. Seperti yang terlihat pada Gambar 9 dilakukan perhitungan sehingga menghasilkan nilai-nilai korelasi seperti yang terlihat pada Tabel 3.



```
1 # Hitung nilai korelasi antara tiap fitur cuaca dengan Electricity_Consumption
2 corr_matrix = df.corr(numeric_only=True)
3
4 corr_matrix[['Electricity Consumption (MWh)']]\
5 .drop('Electricity Consumption (MWh)', axis=0)\
6 .sort_values(by='Electricity Consumption (MWh)', ascending=False)
```

Gambar 9. Perhitungan R^2 Untuk Setiap Features Dengan Target

Berdasarkan perhitungan tersebut didapatkan nilai korelasi pearson sebagai berikut:

Tabel 3 Nilai Korelasi Pearson Masing Masing Feature

Feature	Korelasi Pearson
Temperature	0.652811
Wind Speed	0.098435
Precipitation	0.073109
Humidity	-0.036706

Berdasarkan hasil dari output program seperti yang terlihat pada Tabel 3 di atas maka komponen cuaca yang memiliki nilai korelasi tertinggi adalah Temperature dengan nilai 0.652811 diikuti oleh wind_Speed dengan nilai 0.098435, kemudian Precipitation dengan nilai 0.073109 dan terakhir Humidity dengan nilai -0.036706.

Temperature (C) dengan nilai 0.652811 menunjukkan bahwa variabel tersebut memiliki hubungan linear dengan Electricity Consumption (MWh), visualisasi dari heatmap korelasi Pearson juga mendukung hal tersebut dimana hubungan antara Temperature dan Electricity Consumption memiliki nilai korelasi tertinggi dibandingkan variabel lainnya.

2. Bangunlah **model regresi linear** antara komponen cuaca yang mempunyai correlation coefficient **TERTINGGI** (jika dibandingkan dengan electricity consumption) dengan electricity consumption dengan menggunakan Least Square Method **ATAU** Gradient Descent.


Berdasarkan perhitungan pada No.1 ditentukan bahwa komponen cuaca yang mempunyai correlation coefficient tertinggi adalah Temperature. Pembangunan model regresi linear pada No.2 akan menggunakan Gradient Descent dengan nilai alpha 0.01 dan epochs 1000 seperti yang terlihat pada Gambar 10. Pemilihan nilai *learning rate* (α) sebesar 0.01 dan jumlah iterasi (*epochs*) sebanyak 1000 didasarkan pada pertimbangan stabilitas dan konvergensi dalam proses optimasi menggunakan metode *Gradient Descent*. Nilai α yang terlalu besar berisiko menyebabkan model gagal konvergen atau melampaui minimum global (*overshooting*), sementara nilai yang terlalu kecil akan memperlambat proses pelatihan secara signifikan. Dalam hal ini, $\alpha = 0.01$ dianggap cukup kecil untuk memastikan pembaruan parameter yang stabil namun masih cukup besar untuk mencapai konvergensi dalam jumlah iterasi yang wajar. Adapun pemilihan 1000 *epochs* bertujuan untuk memberikan cukup waktu bagi algoritma untuk menemukan nilai parameter terbaik tanpa overfitting.

```
1 # Membangun model regresi linear menggunakan gradient descent terhadap Temperature (fitur dengan R² tertinggi) dengan Electricity_Consumption
2
3 # Ambil fitur dan target (Temperature dan Electricity Consumption)
4 X = df_clean['Temperature'].values
5 y = df_clean['Electricity_Consumption'].values
6
7 # Normalisasi fitur (opsional, membantu konvergensi gradient descent)
8 X_norm = (X - np.mean(X)) / np.std(X)
9 y_norm = (y - np.mean(y)) / np.std(y)
10
11 # Inisialisasi parameter
12 m = 0 # slope
13 b = 0 # intercept
14 alpha = 0.01 # learning rate
15 epochs = 1000
16 n = len(X_norm)
17
18 # Gradient Descent
19 for _ in range(epochs):
20     y_pred = m * X_norm + b
21     error = y_pred - y_norm
22
23     # Hitung turunan
24     dm = (2/n) * np.dot(error, X_norm)
25     db = (2/n) * np.sum(error)
26
27     # Update parameter
28     m -= alpha * dm
29     b -= alpha * db
30
31 # Ubah kembali ke skala asli (denormalisasi)
32 slope = m * (np.std(y) / np.std(X))
33 intercept = np.mean(y) + b * np.std(y) - slope * np.mean(X)
34
35 print(f"Slope (m): {slope:.4f}")
36 print(f"Intercept (b): {intercept:.4f}")
```

Gambar 10. Pengembangan Model Regresi Linear

Berdasarkan hasil gradient descent didapatkan bahwa nilai slope (m) sebesar 74.8359 dan nilai intercept (b) sebesar -867.5690.


- a. Visualisasikan data antara komponen cuaca terhadap electricity consumption dalam bentuk Scatter plot.



Gambar 11. Scatter Plot Antara Fitur Cuaca Dengan Electricity Consumption

Pada Gambar 11 dapat dilihat scatter plot antara fitur-fitur cuaca dengan konsumsi listrik, dari 4 fitur cuaca yaitu Temperature, Humidity, Precipitation, dan Wind Speed terlihat bahwa hanya fitur Temperatur yang terlihat memiliki pola positif terhadap Electricity Consumption yaitu semakin tinggi suhu semakin besar konsumsi listrik. Hal ini sesuai dengan nilai korelasi pearson dimana fitur Temperature memiliki nilai korelasi tertinggi.

- b. Visualisasikan hasil model regresi untuk poin (a) berupa garis linear dan tuliskan hasil model regresi (berupa persamaan garis).




Gambar 12. Visualisasi Scatter Plot dan Garis Regresi

Gambar 12 merupakan visualisasi hasil regresi linier sederhana antara suhu udara (Temperature (C)) sebagai variabel input dan konsumsi listrik (Electricity

Consumption (MWh)) sebagai output. Titik-titik biru menggambarkan data aktual dari hubungan antara suhu dan konsumsi listrik. Terlihat ada kecenderungan bahwa semakin tinggi suhu, konsumsi listrik cenderung meningkat. Garis merah adalah garis regresi hasil dari metode Gradient Descent, yang menunjukkan prediksi model terhadap pola hubungan linier antara kedua variabel. Meskipun garis regresi menangkap arah tren umum (positif), masih terdapat penyebaran data yang cukup lebar dan beberapa outlier, menunjukkan bahwa model memiliki akurasi sedang.

Persamaan Garis Regresi: $Y = 74.8359 * X + -867.5690$
Electricity Consumption = $74.8359 * \text{Temperature} + -867.5690$

- c. bahas mengenai keakuratan dari model tersebut.



```
1 # C. Membahas tentang hasil model regresi yang didapatkan
2
3 # Menghitung R², MAE, dan RMSE untuk model regresi yang dibangun
4 mae = mean_absolute_error(y, y_pred)
5 rmse = np.sqrt(mean_squared_error(y, y_pred))
6
7 print(f"mean_absolute_error: {mae:.4f}")
8 print(f"root_mean_squared_error: {rmse:.4f}")
```

Gambar 13. Perhitungan Keakuratan Model

Menggunakan bantuan Python kita dapat menghitung error dari model untuk mengetahui keakuratan model tersebut. Berdasarkan perhitungan yang dilakukan seperti pada Gambar 13 didapatkan:

mean_absolute_error: 119.4088
root_mean_squared_error: 145.4946

1. Mean Absolute Error (MAE): 119.41 MWh

MAE mengukur rata-rata selisih absolut antara nilai prediksi dan nilai aktual konsumsi listrik. Sehingga menunjukkan:

Rata-rata, model melakukan kesalahan prediksi sebesar ± 119.41 MWh per jam.

MAE tidak sensitif terhadap outlier, sehingga cocok untuk mengukur performa secara umum.

2. Root Mean Squared Error (RMSE): 145.49 MWh

RMSE memberikan penalti lebih besar untuk error yang besar (karena dihitung kuadrat), sehingga menunjukkan:

Terdapat beberapa prediksi yang jauh meleset dari nilai aktual, sehingga meningkatkan nilai RMSE.

Nilai RMSE yang lebih tinggi dari MAE menandakan adanya outlier atau deviasi besar dalam sebagian data prediksi

Kesimpulan

Model regresi linier sederhana yang dibangun menggunakan suhu udara sebagai satu-satunya variabel prediktor mampu menjelaskan sekitar 65.3% variasi konsumsi listrik. Meskipun menunjukkan adanya hubungan linier sedang, nilai error yang cukup besar (MAE 119,4 MWh dan RMSE 145,5 MWh) mengindikasikan bahwa model ini belum cukup akurat untuk prediksi yang andal.